9. 파이프라인과 앙상블 모델

chap09_Ensemble 수업내용

1. Pipeline 모델
2. Ensemble 모델 개요
3. RandomForest
4. XGBoost

1. Pipeline 모델

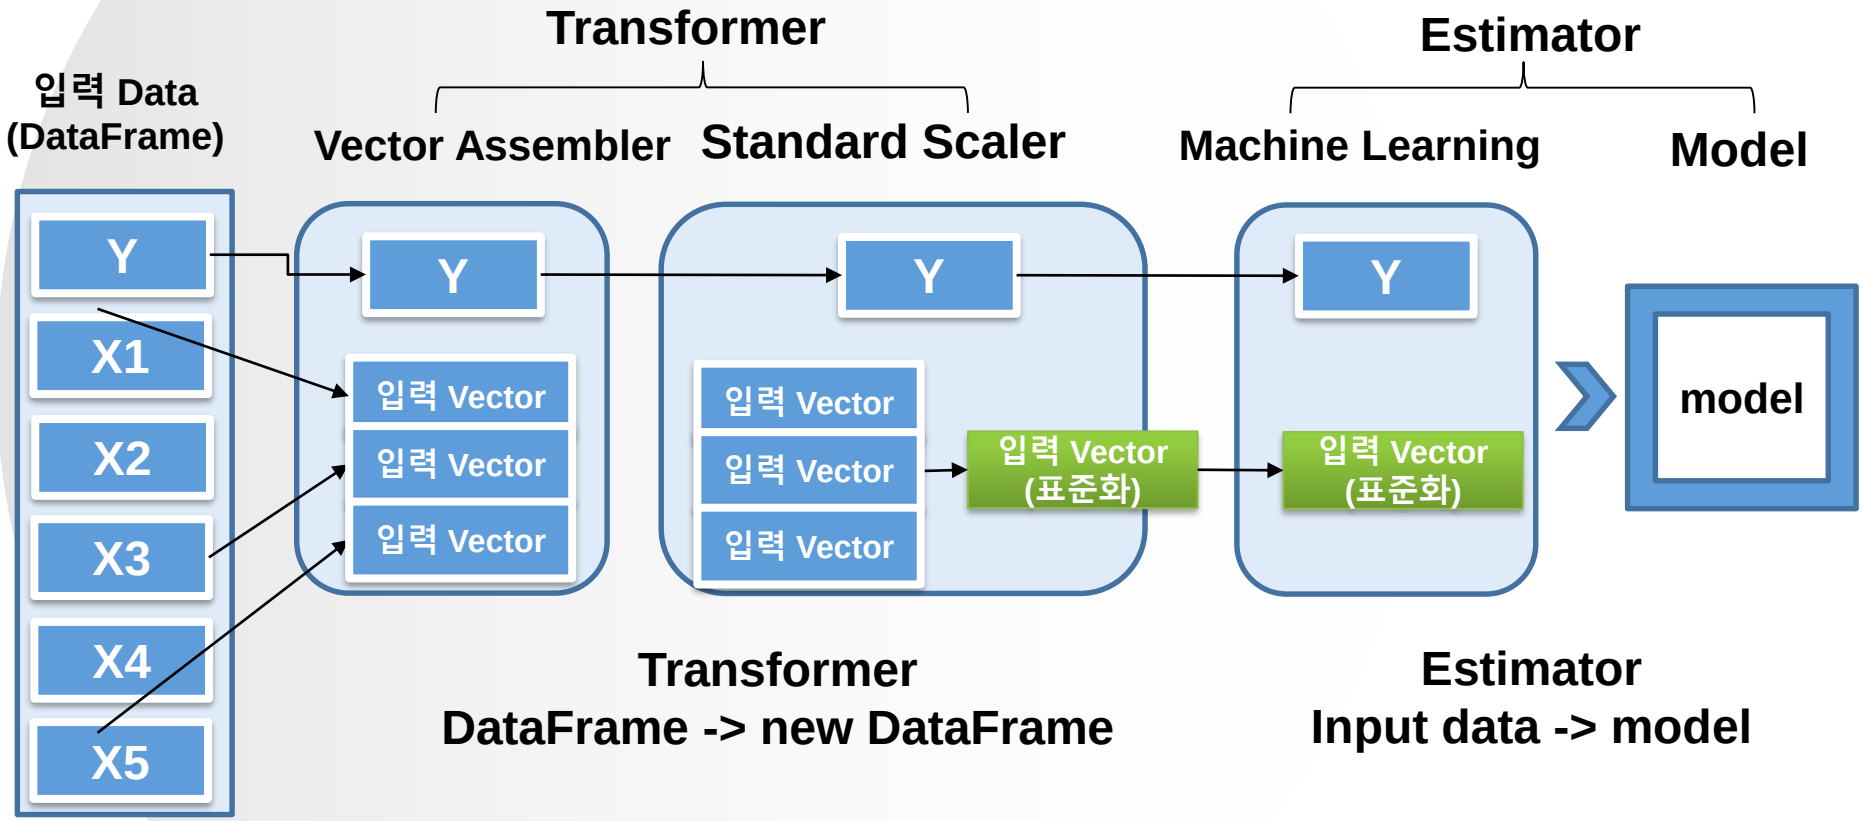

2. Ensemble 모델 개요

- 앙상블 학습
  - ➢ 여러 가지 우수한 학습 모델을 조합해 예측력을 향상시키는 모델
    - ✓ 장점 : 단일 모델에 비해서 분류 성능 우수
  - ➢ 앙상블 알고리즘
    - ✓ 배깅(Bagging), 부스팅(Boosting)
      - ▪ RandomForest 배깅 알고리즘의 일종
  - ➢ 앙상블 학습 모델 생성 절차

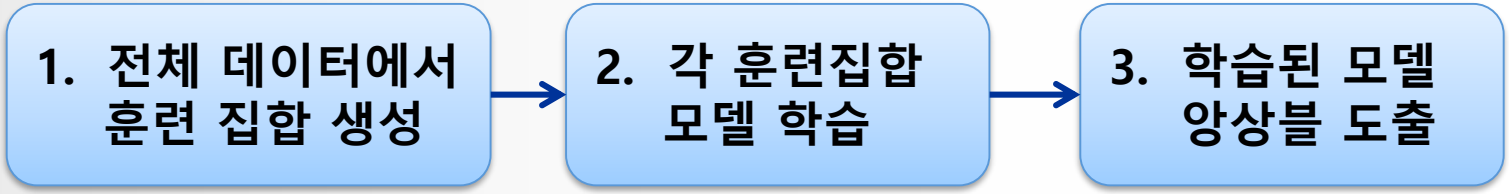

※ 단점 : 모델 결과의 해석이 어렵고, 예측 시간 많이 소요

2. Ensemble 모델 개요

- **앙상블 학습 알고리즘 비교**

분류	배깅(Bagging)	부스팅(Boosting)
공통점	전체 데이터 집합으로부터 복원 랜덤 샘플링(bootstrap)으로 훈련 집합 생성	
차이점	병렬학습 : 각 모델의 결과를 조합하여 투표 결정	순차학습 : 현재 모델 가중치 -> 다음 모델 전달
특 징	균일한 확률분포에 의해서 훈련 집합 생성	분류하기 어려운 훈련 집합 생성
강 점	과대적합에 강함	높은 정확도
약 점	특정 영역 정확도 낮음	Outlier 취약
R 패키지	randomForest	XGboost

2. Ensemble 모델 개요

- 앙상블 학습 알고리즘

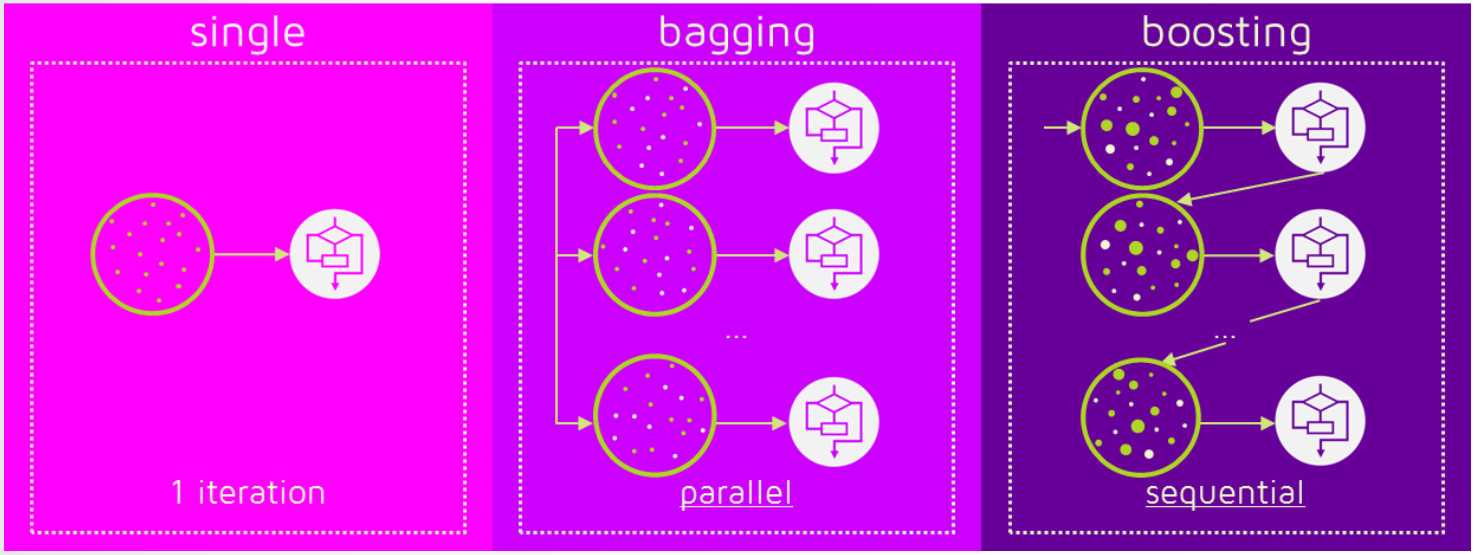

※ Boosting은 맞추기 어려운 문제를 맞추는데 초점을 맞춤

① 부트스트랩(Boostrap)

- 원래의 데이터 셋으로부터 관측치를 반복적으로 추출(복원 반복 추출)하여 데이터 셋을 얻는 방법
- 데이터의 양을 임의적으로 늘리고, 데이터 셋의 분포가 고르지 않을 때 고르게 만드는 효과

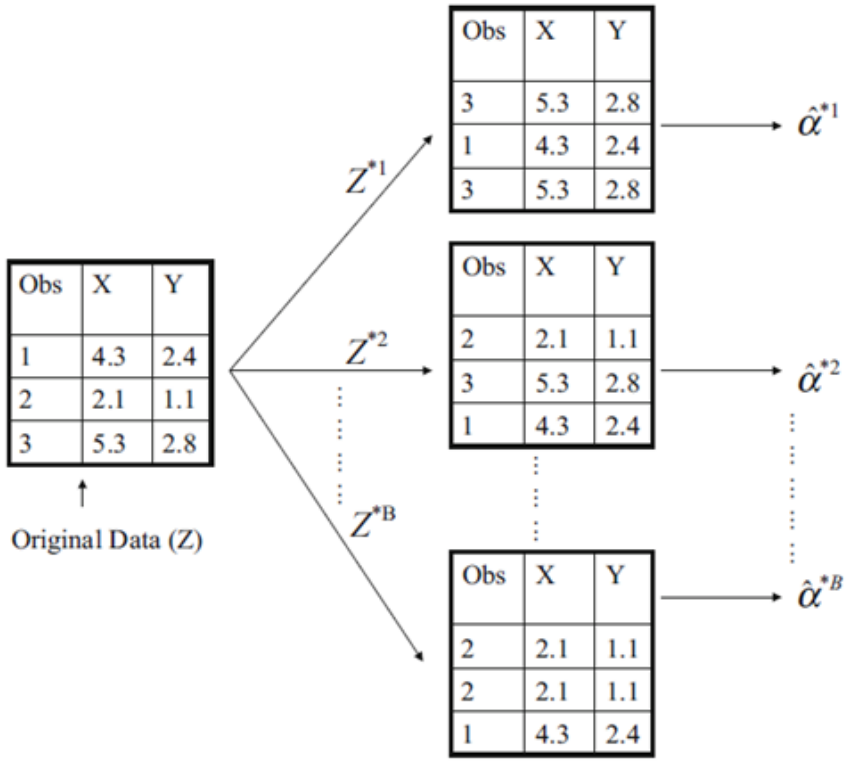

[참고 사이트]
https://m.blog.naver.com/PostView.nhn?blogId=ysd2876&logNo=221219689884&isFromSearchAddView=true

② 배깅(Bagging) 알고리즘

- Bagging : Bootstrap Aggregating(“주머니 통합”)
- 부트스트랩을 통해서 조금씩 서로 다른 훈련 데이터를 생성하여 모델(훈련 된 트리)을 생성하고, 결과를 결합(aggregating) 시키는 방법

1. D개의 전체데이터가 있다.
2. 전체데이터에서 D개와 같은 갯수의 데이터를 복원추출하여 D_1(주머니) 생성
3. D1 데이터를 학습하여 모델(트리) 생성
4. 위 2번, 3번과 같은 방법으로 D_m (주머니) 생성, 모델(트리) 생성
5. m개 트리의 평균을 통해 예측
   - 양적반응변수(회귀트리) : 각 트리 평균 예측
   - 질적반응변수(분류트리) : 각 트리 voting 예측

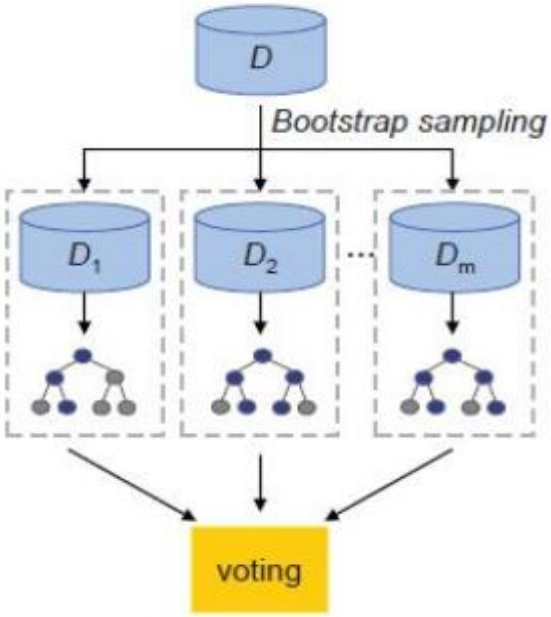

- 원 데이터로 부터 n번 랜덤 복원 샘플링을 하고 각 샘플의 모델링을 통해서 나온 결과변수(예측치)들을 결합하여 최종 모형을 생성
- 각 샘플의 결과변수(예측치)들을 결합하는 방법은 결과변수가 연속형이면 평균(average), 범주형이면 다중 투표(majority vote) 사용

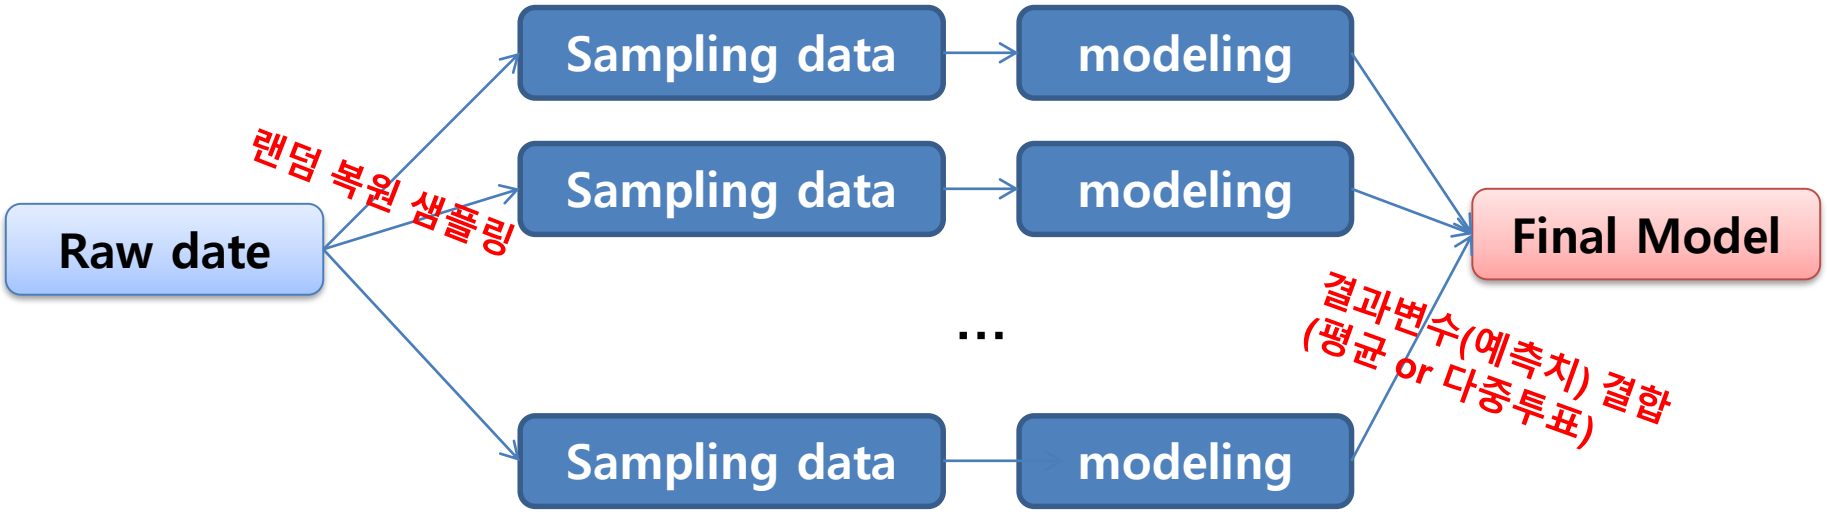

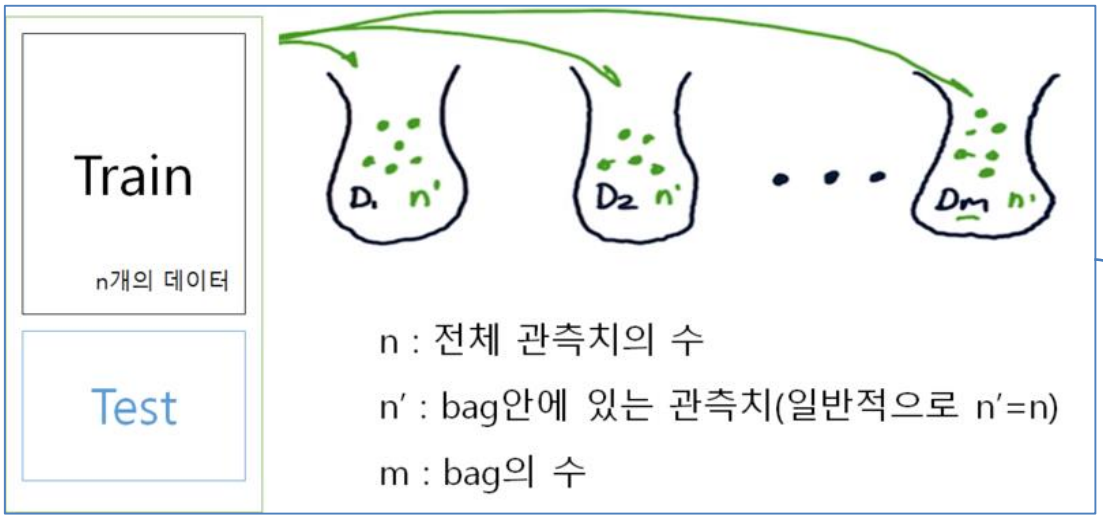

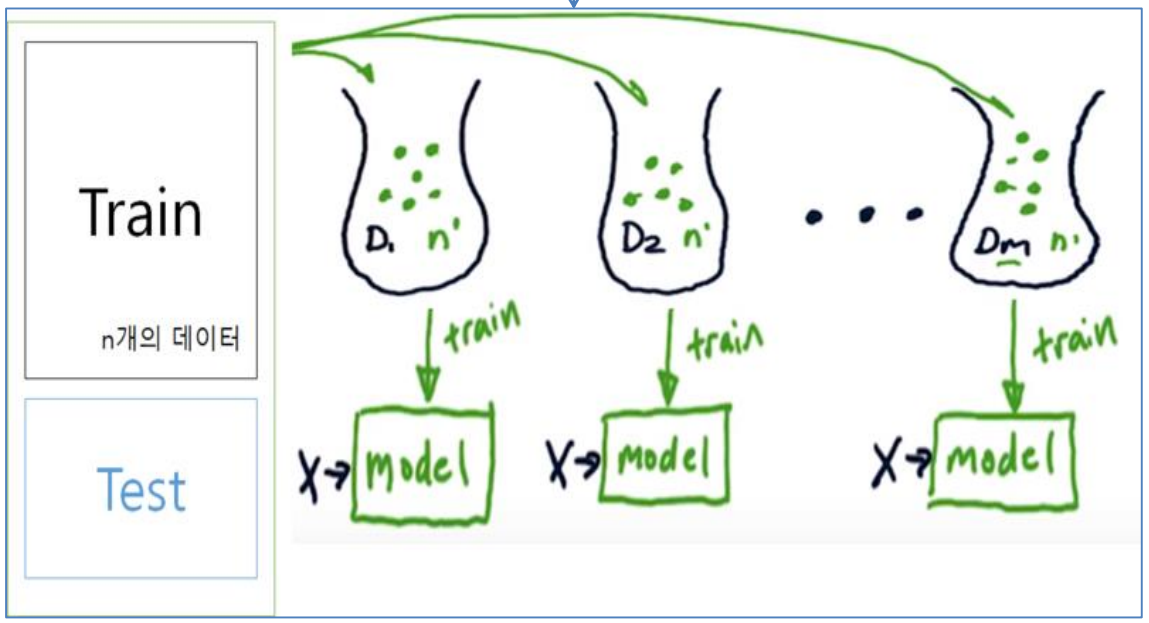

[참고 사이트]
https://m.blog.naver.com/PostView.nhn?blogId=ysd2876&logNo=221219689884&isFromSearchAddView=true

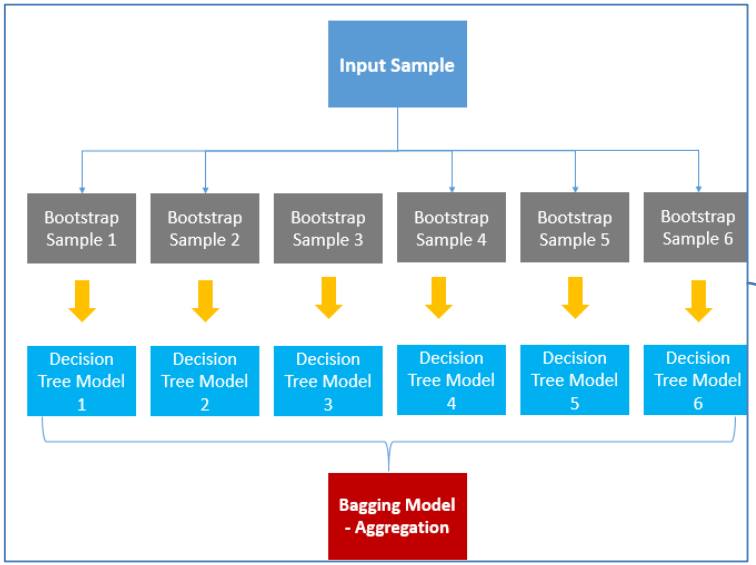

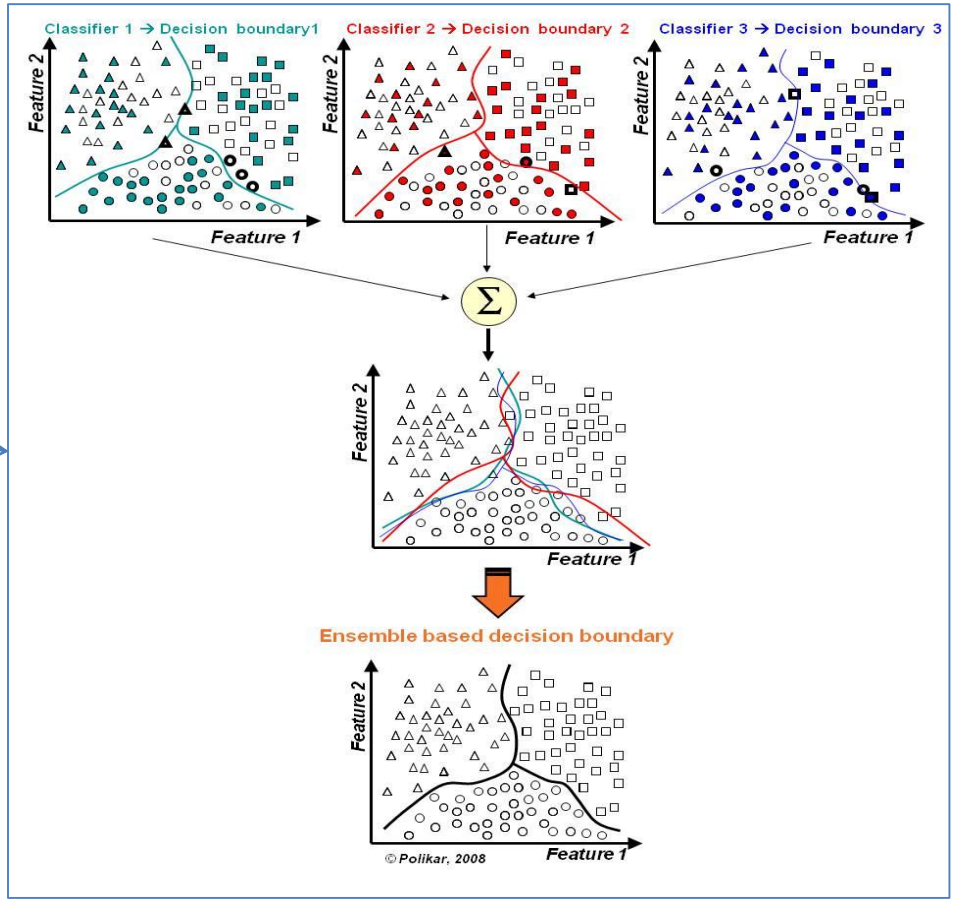

참고 사이트 : https://swalloow.github.io/bagging-boosting

③ 부스팅(boosting) 알고리즘

- 잘못 분류된 객체들에 집중하여 새로운 분류규칙을 생성하는 단계를 반복하는 알고리즘(순차적 학습)
- 약한 예측모형들을 결합하여 강한 예측모형을 만드는 알고리즘
- 오 분류된 개체는 높은 가중치, 정 분류된 개체는 낮은 가중치를 적용하여 예측모형의 정확도를 향상시키기 위한 방법

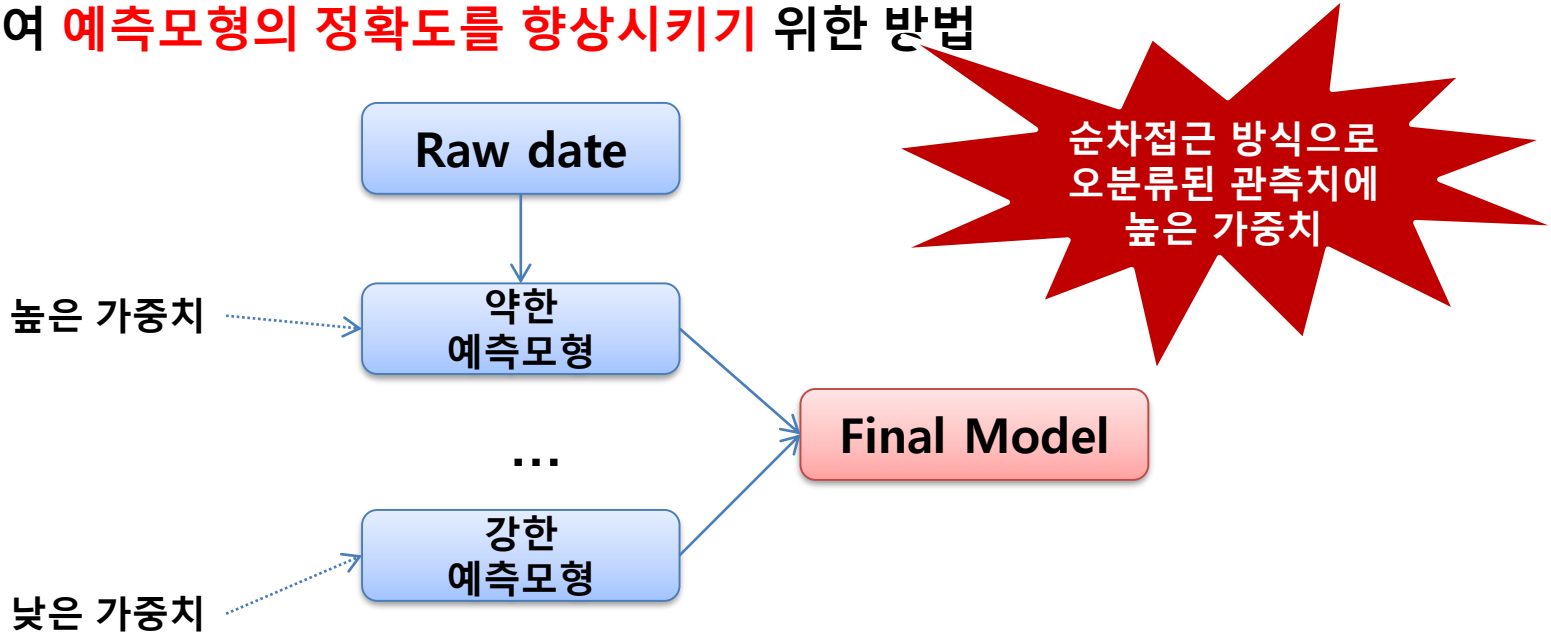

3. Random Forest 알고리즘

- 특징
  - ✓ 여러 개의 결정 트리를 임의적으로 학습하는 방식(앙상블 학습방법 : 배깅 유형)
  - ✓ 회귀분석, 분류분석 모두 가능
  - ✓ 별도 튜닝(스케일 조정) 과정 없음
  - ✓ 분류, 회귀 등에서 가장 많이 사용 학습방법
  - ✓ 단일 tree 모델 단점 보완(성능, 과대적합)
  - ✓ 대용량 데이터 셋으로 처리시간 증가(단점)
  - ✓ 멀티코어 프로세스 이용 병렬처리 가능
- 차이점
  - ✓ 배깅 : 샘플 복원추출 시 모든 설명변수 사용
  - ✓ 랜덤포레스트 : a개의 설명변수만 복원 추출
- 설명변수 갯수 : 전체 변수 p의 제곱근=sqrt(p) (예: 15개 변수라면 4개 정도)
- 랜덤포리스트는 일반적으로 배깅보다 성능 우수
  (설명변수가 많을 경우, 대체로 변수간 상관성이 높은 변수가 섞일 확률이 높은데 그 가능성을 제거)

● Decision tree

1. 동일한 하나의 데이터 집합에서 한 개의 훈련용 데이터를 생성
2. 한 번의 학습을 통해서 하나의 분류 트리 생성 및 목표변수 예측
3. 생성된 분류모델을 검정데이터에 적용하여 목표변수 예측

● Random Forest

1. 동일한 하나의 데이터 집합에서 임의복원 샘플링을 통해 여러 개의 훈련용 데이터를 생성
2. 여러 번의 학습을 통해 여러 개의 트리 생성하고, 이를 결합하여 최종적으로 목표변수 예측
3. 분류모델을 검정데이터에 적용

학습용 데이터 트리

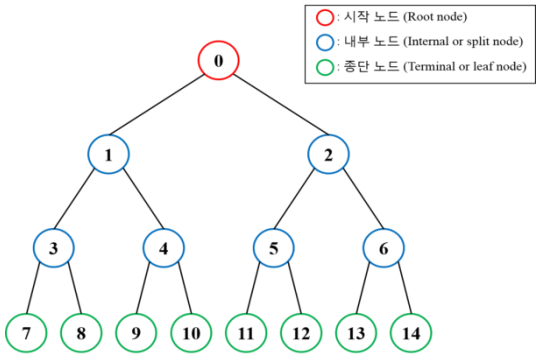

결정 트리

학습용 트리1 학습용 트리2 학습용 트리3

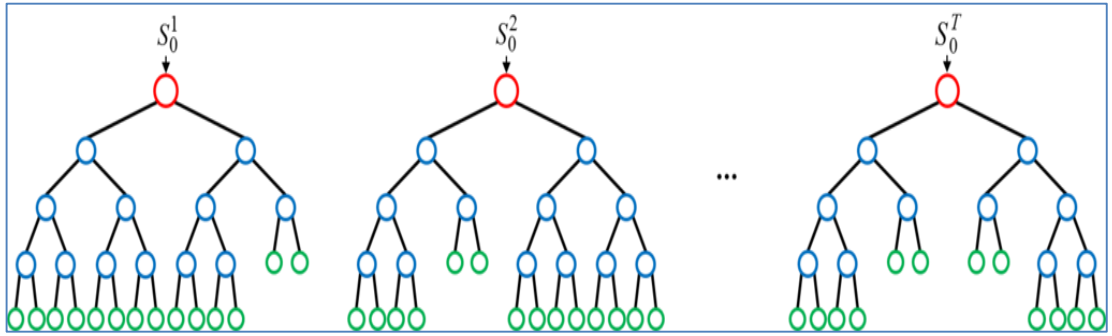

랜덤 포레스트

배깅에 의한 랜덤 포레스트 훈련 과정 3단계

1. 부트스트랩 방법을 통해 T개의 훈련 데이터 집합을 생성한다.
2. T개의기초 분류기(트리)들을 훈련시킨다.
3. 기초 분류기(트리)들을 하나의 분류기(랜덤 포레스트)로 결합한다.

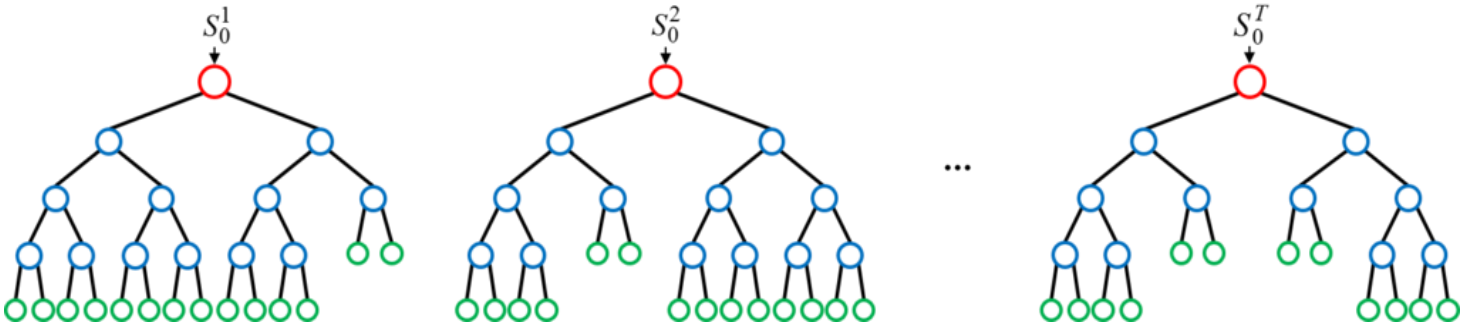

배깅을 이용하여 T개의 결정트리들로 구성된 랜덤 포레스트를 학습하는 과정
S_0:전체 학습 데이터 집합, S^T_0 : 결정트리를 위해 배깅을 통해 임의로 선택된 학습 데이터

● Random Forest 주요 파라미터

1. criterion='gini' : 노드 불순도 - 중요변수 선정기준
2. max_depth : 트리의 깊이(클 수록 서능이 좋아짐, 오버피팅 문제)
3. max_features='auto' : 최대 사용할 x변수 개수
4. n_estimator : 결정 트리 개수(default=10), 많을 수록 성능이 좋아짐
5. n_jobs=None : cpu 사용 수
6. min_sample_leaf : leaf node를 만드는데 필요한 최소한의 sample 수
7. min_sample_split : 내부 노드를 분할하는 데 필요한 최소 sample 수

● Random Forest 사용 이유

1. 단일 의사결정트리는 과대적합(overfitting)의 위험이 큼
2. 배깅을 이용해 각 트리의 평균, 확률, 투표를 통해 목표변수 예측
3. 트리의 편향은 유지되고, 분산은 감소되기 때문에 정확도 높음
4. 빅데이터 시스템에서 분산처리 시스템에 맞는 분류분석 기법
   - 여러 개의 훈련 데이터를 추출하여 트리 생성, 결합을 통해 목표변수 예측의 구조가 분산처리시스템에 적합

- 정리

1. 배깅 알고리즘을 통해 임의 복원 추출되는 훈련용 데이터를 생성하고, 각 트리 생성
2. 예측결과를 투표, 평균, 확률 등으로 결합하여 최종 모형 생성
3. 적용되는 R 패키지 : ramdomForest

4. XGBoost 알고리즘

- 여러 개의 결정 트리를 임의적으로 학습하는 방식
  - ✓ 앙상블 학습방법(부스팅 유형)
- 순차적 학습 방법 : 약한 분류기를 강한 분류기로 생성
  - ✓ 분류정확도 우수, Outlier 취약
  - ✓ 케글(Keggle.com) : 도전 데이터 과학자 에서 5년 연속 1위
- 다양한 속성으로 모델 생성
  - objective='binary:logistic' : 'reg:linear', 'multi:softmax'(num_class)
  - max_depth=3 : tree 깊이, 과적합 영향(tree 구조가 간단한 경우 : 2)
  - nthread = 2 : cpu 사용 수 : 2
  - nrounds = 2 : 실제값과 예측값의 차이를 줄이기 위한 반복학습 횟수
  - learning_rate=0.1 : 학습율(보통 : 0.01~0.2, Default: 0.3)